

Rapport : Analyse multimodale de données d'athlètes

1) Contexte

Trois sportifs ont été suivis de novembre 2019 à mars 2020, avec plusieurs sources de données :

- un capteur Fitbit ;
- des questionnaires remplis quotidiennement ;
- des déclarations de séances, de blessures et de repas.

L'objectif est d'abord de regrouper et de nettoyer ces informations afin de construire

Une table utilisable pour entraîner des modèles de machine learning.

Deux questions sont ensuite étudiées :

1. Le joueur est-il en état de suivre un entraînement ? Prédire un indice de préparation ;
2. Risque-t-il de se blesser ? Prédire le risque de blessure.

L'audit préalable révèle des limites qui conditionnent ces deux objectifs :

- ⇒ 4 épisodes de blessure distincts sur l'ensemble des participants, et des
- ⇒ Protocoles de déclaration hétérogènes d'un sujet à l'autre.

Les données disponibles et état de l'art pour construire un indice de préparation

Fitbit fournit des données objectives sur l'activité physique, la fréquence cardiaque, le sommeil et les séances détectées.

Les questionnaires quotidiens fournissent des informations sur la fatigue, l'humeur, la qualité du sommeil, les courbatures, le stress et la disponibilité perçue du joueur (readiness). Ces variables sont proches des dimensions utilisées dans le suivi quotidien des athlètes, notamment dans l'approche de Hooper et Mackinnon (1995) .

On dispose également d'informations ponctuelles sur les séances d'entraînement : effort perçu et durée et ainsi que sur les blessures et l'alimentation.

Le jeu de données ne contient **aucune mesure directe de la performance sportive** : ni temps, ni puissance, ni résultat de test physique ni de compétition. Il n'est donc pas possible de construire un score de performance validé par rapport à un critère objectif.

À la place, je construis un indice de readiness, un indicateur de l'état de préparation du joueur, à partir des informations disponibles. Cette notion est utilisée dans la littérature pour décrire l'état de préparation ou de récupération d'un athlète (Sansone et al., 2023).

Une distinction importante oriente la suite : Saw et al. (2016), dans une revue systématique de 56 études, établissent que mesures subjectives et objectives du bien-être ne corrèlent généralement pas, les premières reflétant la charge d'entraînement avec une sensibilité supérieure.

Le lien entre readiness et performance n'est d'ailleurs pas établi, y compris lorsque les deux sont mesurés. Janetzki et al. (2023) ont systématisé 165 études et méta-analysé vingt marqueurs de readiness : seule la hauteur de saut vertical prédit la vitesse sur 10 mètres ($r = 0,69$), les marqueurs physiologiques et biochimiques : cortisol salivaire, fréquence cardiaque sous-maximale, variabilité cardiaque, protéine C-réactive ne montrent pas d'association significative avec la performance.

2) Audit des données

La construction de la table (une ligne par participant et par jour) a été précédée d'un audit des sources, les décisions de traitement dépendent de ce que les fichiers contiennent réellement. Cinq constats en ressortent

Couverture hétérogène

Les 3 sujets couvrent la même période, mais présentent des disponibilités très différentes : 152 jours de données Fitbit pour p01, 144 pour p05 et 122 pour p03.

Les jours manquants forment des blocs de 23 jours consécutifs chez p03 en novembre-décembre, et de 6 jours chez p05 fin février, plutôt que des trous dispersés, ce qui oriente vers des périodes sans port du bracelet. P03 ne dispose par ailleurs d'aucun fichier de fréquence cardiaque (Figure 1)




Figure 1 : Concordance des sources par participant. Chaque trait représente un jour renseigné. Le bloc manquant de p03 en novembre-décembre et l'absence complète de la fréquence cardiaque y sont visibles.

Valeurs générées par le capteur

Le fichier **calories.json** compte exactement **218 880 lignes pour les trois participants**, soit $152 \text{ jours} \times 1440 \text{ minutes}$. Fitbit produit une valeur à chaque minute, indépendamment du port réel, alors que les fichiers de pas comptent de 53 042 à 218 836 lignes.

La complétude apparente des calories, à 100 %, était donc trompeuse. Sur les jours sans données de pas, l'écart-type des calories est de 6,5, contre 550 sur les jours renseignés : signe d'un métabolisme de base calculé plutôt que mesuré.

Charge d'entraînement déclarée inexploitable

Le sRPE, **mesure de référence de la charge interne**, n'est renseigné que pour 34 séances pour p01, 9 pour p05 et 2 pour p03 sur cinq mois. Cette source ne permet pas de construire un indicateur comparable entre les participants ; les données d'activité du capteur ont été utilisées à sa place.

Protocoles de déclaration hétérogènes

Participant	Déclarations	Positives	Taux
p01	24	1	4,2 %
p03	11	0	0 %
p05	10	10	100 %

p01 renseigne le formulaire régulièrement, qu'il soit blessé ou non ; p05 ne le renseigne qu'en cas de blessure. Les trois participants ne mesurent donc pas le même phénomène.

Épisodes non indépendants

Les huit déclarations de p05 localisées au pied gauche s'échelonnent du 30 janvier au 17 mars, avec des écarts de 1 à 15 jours, après 84 jours sans déclaration. Cette structure correspond à **un épisode persistant** redéclaré plutôt qu'à huit blessures distinctes.

Après regroupement des déclarations consécutives sur une même zone anatomique, le nombre d'épisodes distincts tombe à quatre : deux gênes isolées chez p05 en novembre (pied gauche, cou), un épisode prolongé au pied gauche de janvier à mars, et une atteinte à la main droite chez p01. Aucun ne présente les caractéristiques d'une lésion de surcharge.

Avant de passer à l'étape suivante

En tant que data scientist, je demanderais au fournisseur de retrouver le fichier `heart\_rate.json` manquant sur p03 avant d'aller plus loin. Il ne s'agit pas de valeurs non enregistrées mais d'un fichier absent de la livraison : l'information existe probablement à la source, et aucune imputation ne peut reconstituer 152 jours de fréquence cardiaque.

Je vérifierais également les protocoles de déclaration : p05 ne renseigne le formulaire de blessure que lorsqu'il est blessé, ce qui rend sa cible incomparable à celle des autres. Un protocole homogène pour déclarer l'absence de blessure, tout comme sa présence, est un prérequis pour toute modélisation.

⇒ Revoir le protocole et les consignes données

3) Construction du jeu de données

Les sources présentent des granularités hétérogènes : la minute pour les flux d'activité et la fréquence cardiaque, l'événement pour les séances et les nuits, et la journée pour les questionnaires. L'unité d'analyse retenue est le couple participant-jour.

La fusion s'appuie sur une grille complète de 152 jours par participant, plutôt que sur les dates figurant dans les fichiers : les jours sans données apparaissent ainsi comme des valeurs manquantes, au lieu de disparaître. La table obtenue compte 456 lignes et 52 colonnes. La figure 2 montre la proportion de jours renseignés pour chaque source et chaque participant.




Figure 2 Complétude des sources par participant. Trois niveaux apparaissent, du capteur porté aux déclarations ponctuelles

Cas de la fréquence cardiaque

Pour la fréquence cardiaque, 1 440 mesures par jour sont résumées par plusieurs statistiques complémentaires : la moyenne, qui donne un état général, le minimum, proche de la fréquence de repos, le maximum, qui indique l'effort le plus intense, et l'écart-type, qui mesure la variabilité au cours de la journée.

Deux indicateurs de qualité sont conservés : le nombre de minutes effectivement mesurées, et l'indice de confiance fourni par le capteur. Une moyenne calculée sur 300 minutes ne vaut pas une moyenne calculée sur 1 400 minutes.

Données nutritionnelles

Les métadonnées EXIF des photographies ont été extraites par un script dédié : 321 images traitées pour p01, avec un taux de réussite de 100 % pour l'extraction. Elles fournissent la date et l'heure de chaque prise, le nombre de prises par jour et, lorsque le nombre de prises le permet, l'amplitude de la fenêtre alimentaire.

L'estimation calorique à partir du contenu des images a été écartée. Fridolfsson et al. (2025) rapportent une erreur absolue moyenne de 35,8 % sur l'énergie pour les meilleurs modèles multimodaux, avec une sous-estimation systématique qui s'aggrave avec la taille des portions. Les pipelines classiques reposent par ailleurs sur un objet de calibration absent ici, et aucune vérité terrain nutritionnelle n'accompagne les images : une telle erreur serait invérifiable.

L'apport calorique est donc estimé par bilan énergétique, la dépense mesurée servant d'estimation de l'apport à poids stable, répartie selon la structure des repas déclarés. Cette variable est indicative et n'est pas retenue comme prédicteur.

Pistes pour une estimation calorique : Avec davantage de temps, trois approches seraient envisageables.

- Un modèle vision-langage interrogé via une API, dont l'erreur attendue est de l'ordre de 35 %, acceptable comme outil de dépistage, mais non comme mesure. Il faudrait alors modifier le protocole de collecte afin d'inclure un objet de référence dans le champ.
- Un modèle de classification pré-entraîné sur des images d'aliments, suivi d'une table de correspondance calorique par catégorie. L'erreur porterait alors sur l'estimation de la part plutôt que sur la reconnaissance. Une approche hybride enfin, que recommande Chotwanvirat et al. (2024)

Combiner l'image avec une saisie contextuelle de l'utilisateur plutôt que de s'appuyer uniquement sur l'image. C'est la logique retenue ici, en croisant les photographies et les repas déclarés.

Dans tous les cas, une validation supposerait une vérité terrain nutritionnelle absente de ce jeu de données.

4) Pré-traitement des données

Trois principes ont guidé ce prétraitement

Ne jamais écraser une mesure. Toute valeur imputée est conservée dans une colonne distincte, la variable d'origine restant intacte, et une colonne indicatrice indique les lignes concernées. Cela permet de comparer les résultats avec et sans imputation, et garantit que le jeu de données livré reste vérifiable.

S'aligner sur l'existant avant de décider. Si des règles de traitement des données manquantes sont déjà en vigueur en interne, autant les reprendre que d'en inventer. Mes hypothèses seraient testées contre celles en vigueur avant de trancher.

Distinguer l'absence de mesure de l'absence d'événement : Un jour sans séance déclaré n'équivaut pas à un jour sans séance. Un questionnaire non rempli laisse l'état inconnu. Ces situations n'appellent pas le même traitement.

Traitement des valeurs aberrantes

Trois familles d'anomalies ont été identifiées et traitées différemment. Les valeurs générées par le capteur, détectées par le comptage exact des lignes. Les soumissions de questionnaires entièrement à zéro, produisant des moyennes hors échelle, ont été écartées avant l'agrégation. Et six nuits de plus de 700 minutes, conservées comme valeurs extrêmes plausibles après vérification du contexte : leur efficacité de sommeil reste normale et l'activité des jours adjacents est cohérente.

Un cas mérite attention : le readiness de p05 ne prend que deux valeurs, 0 et 5. L'examen de leur répartition mensuelle montre que les zéros se concentrent en novembre et en décembre puis disparaissent, alors que leur période de blessure s'étend de janvier à mars.

⇒ Ces zéros correspondent donc à un champ non renseigné, qui vaut zéro par défaut, et non à un état déclaré. Une valeur formellement valide peut ainsi ne mesurer rien.

Cinq approches décrites **dans le tableau 1** ont été comparées en termes de durée de sommeil, de la plus simple à la plus avancée. Le critère retenu est la préservation de l'écart-type : une méthode qui le réduit fortement écrase une variabilité physiologique réelle.

Tableau 1 Méthodes de remplacement de valeurs aberrantes

Approche	Écart-type	Effet
Valeurs observées	92,3	Référence
Suppression des lignes incomplètes	—	293 lignes sur 456 (−36 %)
Médiane globale	80,4	−13 %
Médiane par participant	80,4	Identique
Propagation 2 jours	94,9	Préservé, 67 manquants résiduels
Imputation multivariée	80,3	Aucun gain

Deux constats complémentaires ont orienté la décision.

- ⇒ L'autocorrélation à un jour d'intervalle est faible pour l'ensemble des variables candidates : 0,03 pour la durée de sommeil, 0,21 pour la fatigue, 0,26 pour la fréquence cardiaque. La valeur de la veille ne constitue donc pas un prédicteur fiable, y compris sur des trous courts. Et l'interpolation cubique produit des valeurs hors de portée : un maximum de 101,4 % pour une efficacité du sommeil bornée à 100 %.

Décision retenue

Le jeu de données livré conserve les valeurs manquantes : il reflète ce qui a été mesuré et laisse à tout utilisateur ultérieur le choix du traitement.

L'imputation est réalisée au sein du pipeline de modélisation, en apprentissage fold par fold, ce qui évite toute fuite d'information vers les données de test.

5) Feature Engineering

Construction des variables

Les valeurs brutes quotidiennes rendent mal compte de deux phénomènes établis en sciences du sport : l'accumulation de charge sur plusieurs jours, et l'écart d'un individu à sa propre norme. **Nous devons construire de nouvelles variables.**

Charge d'entraînement. Le sRPE étant inexploitable (1 à 20 % de complétude), la charge est approchée par le volume d'activité du capteur. Trois indicateurs sont construits.

La charge aiguë cumule l'activité des sept derniers jours. La charge chronique cumule celle des vingt-huit derniers jours, ramenée à une base hebdomadaire. L'ACWR est le rapport des deux : il mesure un écart à l'habitude plutôt qu'un volume absolu. Une valeur de 1,5 indique que le participant a réalisé 50 % de plus que sa moyenne récente.

L'ACWR fait toutefois l'objet de critiques méthodologiques : Impellizzeri et al. (2020) concluent qu'aucune preuve ne soutient son usage et identifient un couplage mathématique entre le numérateur et le dénominateur. Il est conservé à titre conventionnel, les charges brutes demeurant les principaux prédicteurs.

Dette de sommeil. Une revue de 2021 identifie sept heures ou moins comme le seuil associé à un risque accru, l'association apparaissant lorsque le déficit est maintenu sur au moins quatorze jours (risque 1,7 fois supérieur). La variable cumule donc, sur une fenêtre glissante de quatorze jours, l'écart au seuil de 420 minutes pour les nuits déficitaires.

Toutes ces variables sont décalées d'un jour : au moment où un score serait produit, les données du jour même ne sont pas disponibles.

Construction de l'indice de readiness

Le questionnaire contient une question directe de readiness sur une échelle de 0 à 10. Son examen montre qu'elle n'est pas exploitable telle quelle : après correction des zéros, l'écart-type est de 1,41 pour p01 mais de 0,30 et 0,48 pour p03 et p05. La variable ne varie que chez un participant sur trois (figure 4).




Figure 4 Distribution du readiness déclaré. p03 répond 5 dans 74 cas sur 78 ; p05 alterne entre 0 et 5 sans valeur intermédiaire. Seul p01 utilise l'échelle.

Un indice composite a donc été construit à partir des dimensions du questionnaire, selon l'approche de Hooper et Mackinnon. La sélection s'appuie sur l'association de chaque dimension avec le readiness déclaré chez p01.

Tableau 2. Association de chaque dimension du questionnaire avec le readiness déclaré chez p01, seul participant pour lequel cette variable présente une variabilité suffisante. Corrélation de Spearman.

Dimension	Corrélation de Spearman	Retenue
Courbatures	0,61	oui
Fatigue	0,60	oui
Qualité du sommeil	0,27	oui
Stress	-0,15	non
Humeur	0,01	non

Cette analyse a révélé un point non explicité dans la documentation : pour la fatigue et les courbatures, une valeur élevée correspond à un meilleur état, l'échelle mesurant l'absence de symptômes. Une première version de l'indice, construite en inversant ces dimensions, présentait une corrélation de $-0,56$ avec le readiness déclaré ; ce signe négatif a conduit à vérifier la direction réelle de l'échelle. Saw et al. (2016) soulignent que la direction de ces échelles varie selon les études.

L'indice retenu est la moyenne des trois dimensions, ramenée sur 0-100. Il corrèle à 0,66 avec la question directe chez p01, sans l'utiliser, et peut donc être appliqué aux trois participants. Le gain est net : 134 jours renseignés chez p05 contre 77, et un écart-type de 7,1 contre 0,48.

Cela est confirmé par la littérature : Sansone et al. (2023) relèvent que 11 des 15 études de leur revue utilisaient des mesures auto-rapportées non validées.

6) Modélisation

Analyse bivariée

Avant de modéliser, il faut savoir si les prédicteurs sont associés à la cible, et si cette association est la même chez tous les participants.

L'association entre chaque prédicteur et l'indice est donc **mesurée par la corrélation de Spearman**, participant par participant. Une corrélation calculée sur les trois mélangés capterait surtout les différences de niveau entre les individus. Le résultat est net : pour six variables sur dix, le signe s'inverse selon le participant. Ce qui est associé à un meilleur état chez l'un l'est à un moins bon chez l'autre. Seules la charge aiguë et l'ACWR restent négatives partout, ce qui est cohérent avec une dégradation de l'état perçu à charge élevée.

Aucune relation n'étant commune aux trois sujets, un modèle entraîné sur deux d'entre eux appliquera au troisième des associations qui ne s'y vérifient pas.

Protocole de validation

Le leave-one-participant-out (LOPO) est retenu car les observations ne sont pas indépendantes : les 152 jours d'un même participant partagent sa physiologie et son niveau de base. Un découpage aléatoire permettrait au modèle de reconnaître l'individu plutôt que d'apprendre une relation, ce qui surestimerait la performance annoncée.

Avec trois participants, ce protocole revient à entraîner sur deux sujets et à tester sur le troisième. C'est exigeant, et c'est ce qu'on attend d'un système destiné à de nouveaux athlètes, mais trois folds ne permettent aucune conclusion statistique.

Une limite supplémentaire tient à l'hétérogénéité des folds : p01 dispose d'une couverture quasi complète, p03 n'a aucune donnée cardiaque et ne dispose que de la moitié de son questionnaire. Les trois folds n'apportent donc pas la même information, ce qui rend leur moyenne peu interprétable. Le protocole reste néanmoins préférable à un découpage aléatoire, qui permettrait au modèle de reconnaître l'individu et de produire un chiffre flatteur mais faux.

Choix des modèles et des métriques

Deux familles sont comparées pour chaque cible. Un modèle linéaire régularisé : Ridge pour la régression, régression logistique pour la classification : sert de référence : peu de paramètres, pas de surapprentissage sur de petits effectifs, coefficients interprétables. Une forêt aléatoire est ajoutée afin de capter d'éventuelles relations non linéaires. Les paramètres sont fixés a priori plutôt qu'optimisés : trois folds ne permettent pas de rechercher les hyperparamètres sans surapprentissage. Le paramètre `min_samples_leaf` est fixé à 5 pour limiter le surapprentissage sur 350 observations, et `class_weight` à « balanced » pour la classification, la prévalence étant de 27 %.

Pour la régression, l'erreur absolue moyenne est directement interprétable dans l'unité de l'indice, et le R^2 situe le modèle par rapport à une prédiction constante. Pour la classification, la PR-AUC est comparée à la prévalence plutôt qu'à 0,5 : sur des classes déséquilibrées, la ROC-AUC est optimiste, son dénominateur de faux positifs étant dominé par la classe majoritaire. Dans les deux cas, une référence explicite est systématiquement comparée.

Modèle 1 : Indice de readiness

Tableau 3 Performances du modèle de readiness selon la configuration,

Configuration	MAE	R^2
Référence : moyenne du participant	5,24	0,139
Ridge, cible brute	7,36	-0,565
Random Forest, cible brute	6,50	-0,257
Ridge, cible normalisée par participant	0,83	-0,155
Ridge, normalisée + état de la veille	0,74	0,029

Sur la cible brute, les modèles font moins bien que la référence. Le R^2 négatif s'explique par des niveaux d'indice différents entre les participants : 52,2 pour p01, 59,2 pour p03, 56,3 pour p05. Entraîné sur deux sujets, le modèle applique son niveau au troisième. La normalisation individuelle corrige ce biais sans faire passer le R^2 en positif (Tableau 3).

La figure 5 ontre cette difficulté : les distributions de fréquence cardiaque de p01 et p05 se recouvrent à peine. Un modèle entraîné sur l'un s'applique à l'autre avec un niveau de référence inapproprié.




Figure 5 Fréquence cardiaque moyenne chez p01 et p05. Les distributions se recouvrent à peine : un modèle entraîné sur l'une ne convient pas à l'autre.

L'ajout de la veille constitue le seul apport décisif. Autrement dit, le meilleur prédicteur de l'état de demain est l'état d'aujourd'hui ; les variables objectives d'activité et de sommeil n'apportent qu'un gain marginal.

L'analyse bivariée en donne la raison : pour six des dix variables, le signe de l'association avec l'indice s'inverse selon le participant. Seules la charge aiguë et l'ACWR conservent un signe négatif chez les trois.

Ce résultat rejoint la littérature. Saw et al. (2016) établissent, sur la base de 56 études, que les mesures subjectives et objectives ne sont généralement pas corrélées. La difficulté à prédire un indice auto-déclaré à partir de mesures de capteur n'est donc pas propre à ce jeu de données.

Modèle 2 : Risque de blessure

Deux formulations de la cible ont été testées.

- ⇒ **L'état courant propage** chaque déclaration sur 14 jours, durée correspondant aux écarts observés entre déclarations consécutives chez p05 (1 à 15 jours) ; le modèle répond **alors à la question « ce joueur est-il blessé aujourd'hui ? »**.
- ⇒ **Le risque prospectif**, construit par jointure temporelle, porte sur une blessure survenant dans les 7 jours suivants ; il répond à la question **« ce joueur risque-t-il de se blesser », formulation plus conforme à un usage opérationnel.**

Régression logistique pondérée dans les deux cas, avec les mêmes variables et la même validation LOPO

Tableau 4 Score de performance selon les 2 cibles

Cible	Positifs (p01/p03/p05)	ROC-AUC	PR-AUC	Prévalence
État courant	7 / 0 / 83	0,087	0,155	0,270
Risque à 7 jours	8 / 0 / 55	0,266	0,115	0,138

Les deux produisent un classement inversé : une ROC-AUC inférieure à 0,5 ne traduit pas l'absence de signal, mais une inversion systématique. L'examen des probabilités **du tableau 5**, moyennes par participant, l'explique.

Tableau 5 Taux de blessure réel et probabilité moyenne prédite, par participant

Participant	Taux de blessure réel	Probabilité prédite moyenne
p01	4,8 %	0,975
p03	0 %	0,844
p05	100 %	0,209




Figure 6 Probabilités prédites sur la cible prospective. p05, seul participant à présenter des épisodes, reçoit les probabilités les plus basses ; p03, qui n'en déclare aucun, les plus élevées.

Lors de la validation en LOPO, le modèle testé sur p05 a été entraîné sur deux sujets quasi exempts de blessures. Il associe leurs profils d'activité à l'absence de blessure et attribue, par contraste, de faibles probabilités au troisième profil (Figure 6).

Le volume d'alertes varie par ailleurs très peu en fonction du seuil, de 264 à 244, entre 0,2 et 0,7.

Les probabilités étant concentrées en haut de l'échelle. La précision reste à 0,10 quel que soit le seuil, contre une prévalence de 0,27.

La reformulation prospective ne résout donc pas le problème de fond : la cible reste portée par un seul participant, et p03 n'y contribue par aucun événement. Le modèle discrimine les individus, et non un état physiologique. Aucune métrique n'est interprétable.

Ces limites sont celles du domaine : les revues récentes identifient les effectifs réduits, les définitions hétérogènes de la blessure et l'absence de validation externe comme les faiblesses récurrentes des modèles publiés (Leckey et al., 2025). Le choix d'un modèle linéaire plutôt que d'une architecture complexe suit la même logique : l'avantage supposé des modèles sophistiqués n'est pas établi sur de petits effectifs déséquilibrés.

Piste selon la littérature : Les foundation models tabulaires (TabPFN et dérivés) constituent une piste intéressante sur de petits effectifs, régime où ils surpassent le gradient boosting dans les benchmarks récents. Ils n'ont pas été testés ici : la limitation tient à la structure de la cible, et non au choix du modèle.

Conclusion

Ce qui fonctionne. L'agrégation des sources par pas participant-jour produit une table exploitable de 456 lignes. L'indice de readiness, construit à partir du questionnaire, est validé empiriquement ($r = 0,66$ avec la question directe).

Ce qui ne fonctionne pas. La prédiction de blessure repose sur quatre épisodes distincts, aucun d'entre eux n'étant de type de surcharge, et sur des protocoles de déclaration hétérogènes. Le modèle produit une ROC-AUC de 0,087 : il discrimine les individus, pas un état physiologique.

La prédiction de readiness ne dépasse pas la référence, même en ajoutant l'état de la veille ($R^2 = 0,029$). Pour six variables sur dix, le signe de l'association s'inverse selon le participant : aucune relation n'est commune aux trois.

Ce qu'il faudrait : un effectif permettant une validation crédible ; l'ordre de grandeur habituel est de 30 événements. Un protocole de déclaration homogène, imposant de renseigner tant l'absence de blessure que sa

présence. Une distinction des mécanismes lésionnels : la charge d'entraînement ne permet d'approcher que les lésions de surcharge. Et une mesure de performance, absente ici, sans laquelle un indice construit sur des dimensions auto-déclarées ne peut être validé par rapport à un critère externe

Références

- Benson L.C., Stilling C., Owoeye O.B., Emery C.A. (2021). Evaluating methods for imputing missing data from longitudinal monitoring of athlete workload. *Journal of Sports Science & Medicine*, 20(2), 188.
- Chotwanvirat P., Prachansuwan A., Sridonpai P., Kriengsinyos W. (2024). Advancements in Using AI for Dietary Assessment Based on Food Images: Scoping Review. *Journal of Medical Internet Research*, 26, e51432.
- Fridolfsson J. et al. (2025). Evaluation of multimodal large language models for nutritional estimation from food images. *Current Developments in Nutrition*.
- Hooper S.L., Mackinnon L.T. (1995). Monitoring overtraining in athletes. Recommendations. *Sports Medicine*, 20(5), 321–327.
- Impellizzeri F.M., Tenan M.S., Kempton T., Novak A., Coutts A.J. (2020). Acute:Chronic Workload Ratio: Conceptual Issues and Fundamental Pitfalls. *International Journal of Sports Physiology and Performance*, 15(6), 907–913.
- Janetzki S.J., Bourdon P.C., Burgess D.J., Barratt G.K., Bellenger C.R. (2023). Assessing athlete readiness using physical, physiological, and perceptual markers: A systematic review and meta-analysis. *Scientific Journal of Sport and Performance*, 2(3), 339–380.
- Kim Y.J., Kim S. (2020). Missing-Data Handling Methods for Lifelogs-Based Wellness Index Estimation: Comparative Analysis With Panel Data. *JMIR Medical Informatics*.
- Leckey C., van Dyk N., Doherty C., Lawlor A., Delahunt E. (2025). Machine learning approaches to injury risk prediction in sport: a scoping review with evidence synthesis. *British Journal of Sports Medicine*, 59(7), 491–500.
- Sansone P., Rago V., Kellmann M., Alcaraz P.E. (2023). Relationship Between Athlete-Reported Outcome Measures and Subsequent Match Performance in Team Sports: A Systematic Review. *Journal of Strength and Conditioning Research*, 37(11), 2302–2313.
- Saw A.E., Main L.C., Gatin P.B. (2016). Monitoring the athlete training response: subjective self-reported measures trump commonly used objective measures: a systematic review. *British Journal of Sports Medicine*, 50(5), 281–291.